



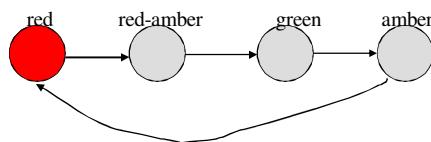
Hidden Markov Model

Forward Algoritması
Viterbi Algoritması

Doç.Dr.Banu Diri

Rasgele Olmayan /Gerekirci Model

Bir trafik lambası düşünelim; ışıkların sırasıyla red - red/amber - green - amber - red. Bu sıralama bir durum makinesi ile görüntülensin ve trafik ışığının her farklı durumu birbirini takip etsin.

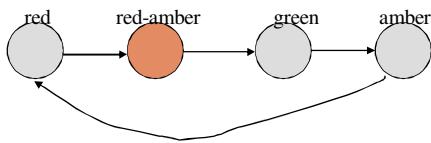


Herbir durum sadece bir öceği duruma bağlıdır, öyleki eğer ışık yeşil ise onu izleyen renk amber olacaktır. Çünkü sistem deterministik. Bu tip sistemlerde bir durumdan diğer bir duruma geçişini anlamak ve analiz etmek kolaydır.

Slide 1

Rasgele Olmayan /Gerekirci Model

Bir trafik lambası düşünelim; ışıkların sırasıyla red - red/amber - green - amber - red. Bu sıralama bir durum makinesi ile görüntülsün ve trafik ışığının her farklı durumu birbirini takip etsin.

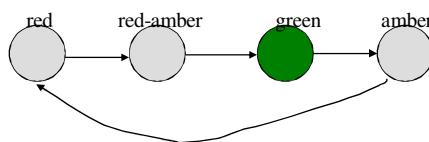


Herbir durum sadece bir öceği duruma bağlıdır, öyleki eğer ışık yeşil ise onu izleyen renk amber olacaktır. Çünkü sistem deterministik. Bu tip sistemlerde bir durumdan diğer bir duruma geçişini anlamak ve analiz etmek kolaydır.

Slide 2

Rasgele Olmayan /Gerekirci Model

Bir trafik lambası düşünelim; ışıkların sırasıyla red - red/amber - green - amber - red. Bu sıralama bir durum makinesi ile görüntülsün ve trafik ışığının her farklı durumu birbirini takip etsin.

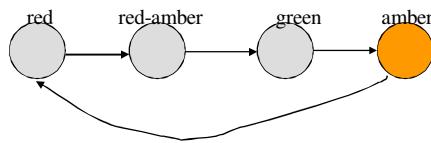


Herbir durum sadece bir öceği duruma bağlıdır, öyleki eğer ışık yeşil ise onu izleyen renk amber olacaktır. Çünkü sistem deterministik. Bu tip sistemlerde bir durumdan diğer bir duruma geçişini anlamak ve analiz etmek kolaydır.

Slide 3

Rasgele Olmayan /Gerekirci Model

Bir trafik lambası düşünelim; ışıkların sırasıyla red - red/amber - green - amber - red. Bu sıralama bir durum makinesi ile görüntülsün ve trafik ışığının her farklı durumu birbirini takip etsin.

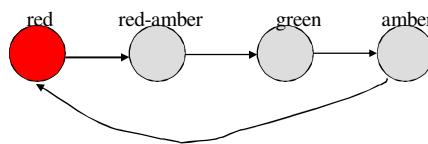


Herbir durum sadece bir öceği duruma bağlıdır, öyleki eğer ışık yeşil ise onu izleyen renk amber olacaktır. Çünkü sistem deterministik. Bu tip sistemlerde bir durumdan diğer bir duruma geçişini anlamak ve analiz etmek kolaydır.

Slide 4

Rasgele Olmayan /Gerekirci Model

Bir trafik lambası düşünelim; ışıkların sırasıyla red - red/amber - green - amber - red. Bu sıralama bir durum makinesi ile görüntülsün ve trafik ışığının her farklı durumu birbirini takip etsin.

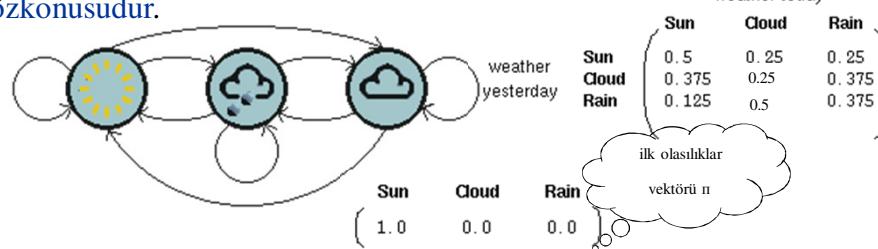


Herbir durum sadece bir önceki duruma bağlıdır, öyleki eğer ışık yeşil ise onu izleyen renk amber olacaktır. Çünkü sistem deterministik. Bu tip sistemlerde bir durumdan diğer bir duruma geçişini anlamak ve analiz etmek kolaydır.

Slide 5

Rasgele Olan /Gerekirci Olmayan Model

Markov modelde bir durumdan diğer bir duruma geçiş önceki n duruma bağlı olarak gerçekleştirilir. Bu işlem *order n* model olarak adlandırılır, n değeri gelecek durumun seçiminde etkili olan durum sayısıdır. N basit Markov model first order ($n=1$) modeldir. Gerekirci modele benzemez, çünkü burada durumların olasılıkları sözkonusudur.



M adet durum (state) varsa maksimum M^2 adet bağlantı (transition) olabilir. Bu bağlantıların olasılıkları da **Transition Matrix** ile verilir.

Slide 6

First order Markov process :

- **states** : 3 durum - sunny, cloudy, rainy.
- **vector (n)**: 0 anında herbir state'in olasılığı
- **state transition matrix** : Verilen bir önceki güne göre havanın ne olabileceğiının olasılığı

Slide 7

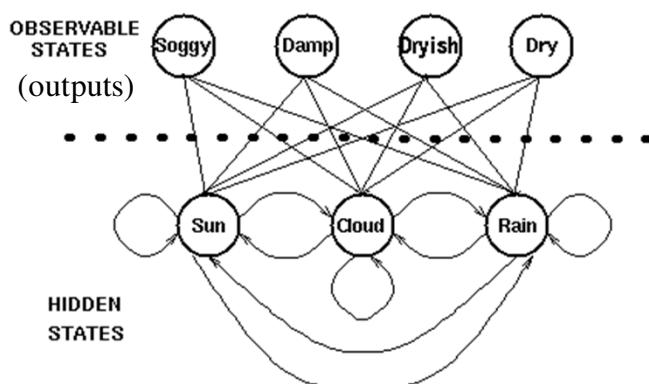
HMM kullanan uygulamalar

- NLP
 - Part-of-speech tagging
 - Word segmentation
 - Information extraction
 - Optical Character Recognition (OCR)
- Speech recognition
 - Modeling acoustics
- Computer Vision
 - gesture recognition
- Biology
 - Gene finding
 - Protein structure prediction
- Economics, Climatology, Communications, Robotics...

Slide 8

Saklı Markov Model (Hidden Markov Model)

Markov modelden farklı olarak Saklı Markov Modelde sistemin herhangi bir t anında, hangi durumda olduğu bilinmez, ancak sistem bir durumda iken bu durumun tetiklediği gözleme ortaya çıkarır.



Slide 9

Saklı Markov model (HMM) bir üçlüdür (π , A, B)

$\Pi = (\pi_i)$ State'lerin başlangıç durumları;

$A = (a_{ij})$ state transition matrix; $Pr(x_{i_t} | x_{j_{t-1}})$

$B = (b_{ij})$ confusion matrix; $Pr(y_i | x_j)$

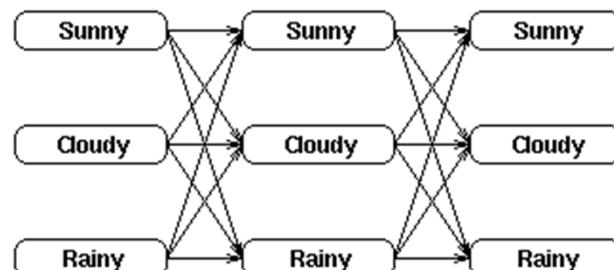
HMM' de üç problem vardır.

1. Gözlemlenen bir sekansın gerçekleşme olasılığının bulunması (Forward Algorithm).
2. Gözlemlere dayanarak saklı state'lerin en muhtemel sekansının bulunması (Viterbi Algorithm).
3. Gözlemlenen sekansın üretilmesi için model parametrelerin belirlenmesi (Forward-Backward).

Slide 10

Forward Algorithm

Gözlemlenen bir sekansın olasılığının bulunması



Observations : dry damp soggy

$Pr(\text{dry}, \text{damp}, \text{soggy} | \text{HMM}) = Pr(\text{dry}, \text{damp}, \text{soggy} | \text{sunny}, \text{sunny}, \text{sunny}) + Pr(\text{dry}, \text{damp}, \text{soggy} | \text{sunny}, \text{sunny}, \text{cloudy}) + \dots + Pr(\text{dry}, \text{damp}, \text{soggy} | \text{rainy}, \text{rainy}, \text{rainy})$

27 farklı durum

Slide 11

$$Y^{(k)} = y_{k_1}, \dots, y_{k_T} \quad T \text{ uzunluğunda gözlemlenen sekans}$$

Intermediate probabilities (α 's) değeri $t=1$ deki bütün state'ler için hesaplanır.

$$\alpha_1(j) = \pi(j) \cdot b_{jk_1}$$

$t = 2, \dots, T$ her adım için her state'in partial probability hesaplanır

$$\alpha_{t+1}(j) = \sum_{i=1}^n (\alpha_t(i) a_{ij}) b_{jk_t}$$

Son olarak bütün partial probability'ler toplanır ve verilen HMM için gözlemlenen sekansın olasılığı hesaplanır.

$$Pr(Y^{(k)}) = \sum_{j=1}^n \alpha_T(j)$$

Slide 12

Hidden States (weather)	Observed States	Initial State Prob. (π vector)
Sunny	Dry	Sunny 0.63
Cloudy	Dryish	Cloudy 0.17
Rainy	Damp	Rainy 0.20
	Soggy	

		Today Weather		
		Sunny	Cloudy	Rainy
Yesterday Weather	Sunny	0.5	0.25	0.250
	Cloudy	0.375	0.125	0.375
	Rainy	0.125	0.675	0.375

		Seaweed				
weather	Sun	Dry	Dryish	Damp	Soggy	
		Cloud	0.60	0.20	0.15	0.05
		Rain	0.25	0.25	0.25	0.25

Slide 13

Forward Algorithm

Finding probability Definition Example Summary

Section 3 - Page 3
1 2 3 4 5

Valid States : Dry Dryish Damp Soggy

Step	Dry, Damp	Sunny	Cloudy	Rainy
Run	D r y	D a m p		

New states have been set

A full description of the model used can be found [here](#).

Page 1

Forward Algorithm

Finding probability Definition Example Summary

Section 3 - Page 3
1 2 3 4 5

Valid States : Dry Dryish Damp Soggy

Step	Dry, Damp	Sunny	Cloudy	Rainy
Run	0.70000001 ■	Sunny	Cloudy	Rainy

Alpha = $(0.63 * 0.6) = 0.37800002$

A full description of the model used can be found [here](#).

Page 1

Forward Algorithm

Finding probability Definition Example Summary

Section 3 - Page 3
1 2 3 4 5

Valid States : Dry Dryish Damp Soggy

	Dry,Damp	Set
Step	$0.70 \cdot 10^{-1}$	Sunny
	$+2.0 \cdot 10^{-2}$	Cloudy
		Rainy
Run	D r y	D a m p

Alpha = $(0.17 * 0.25) = 0.0425$

A full description of the model used can be found [here](#).

Forward Algorithm

Finding probability Definition Example Summary

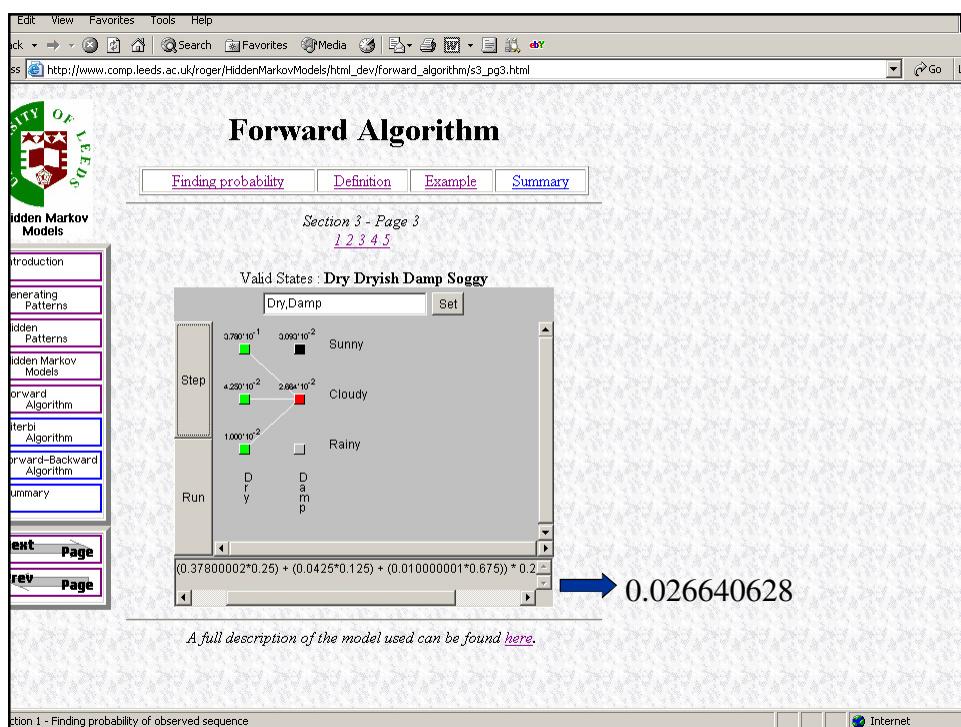
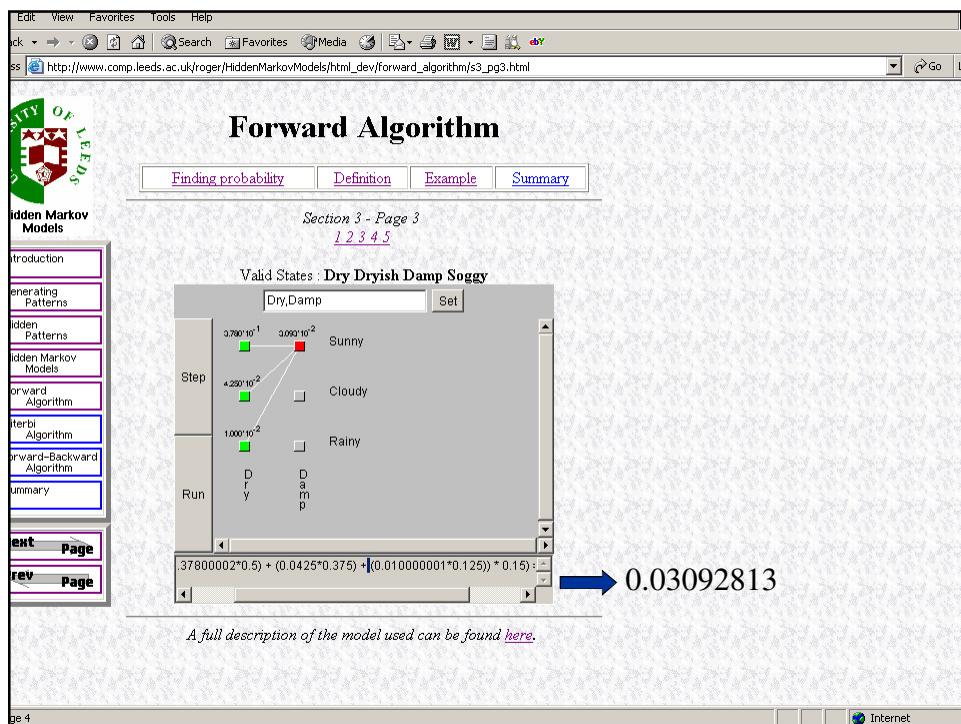
Section 3 - Page 3
1 2 3 4 5

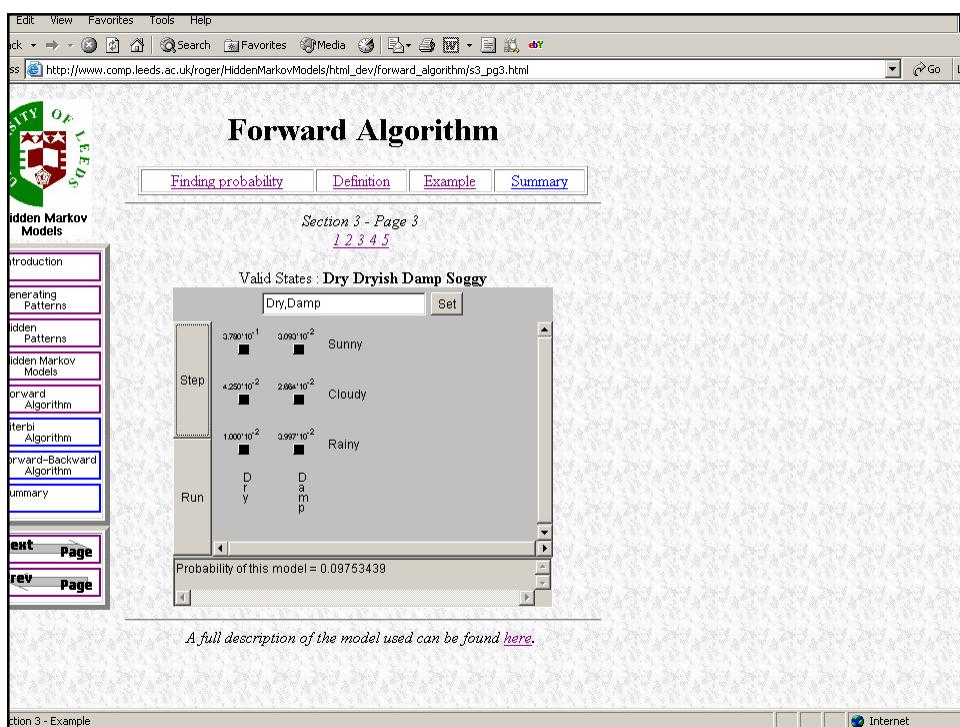
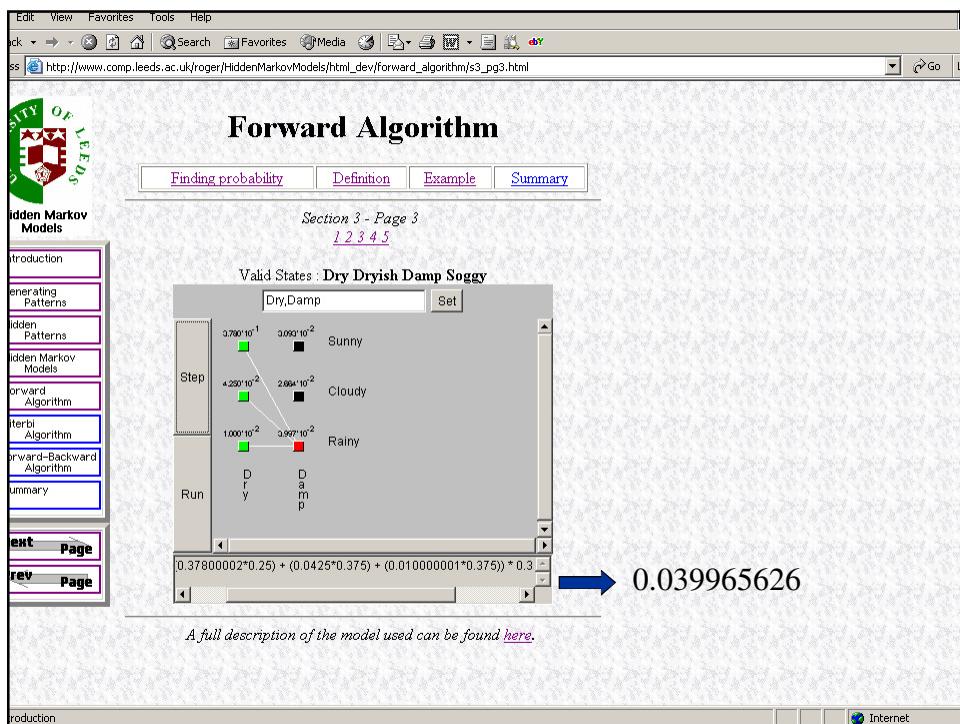
Valid States : Dry Dryish Damp Soggy

	Dry,Damp	Set
Step	$0.70 \cdot 10^{-1}$	Sunny
	$+2.0 \cdot 10^{-2}$	Cloudy
	$1.00 \cdot 10^{-2}$	Rainy
Run	D r y	D a m p

Alpha = $(0.2 * 0.05) = 0.010000001$

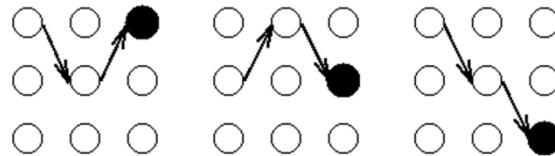
A full description of the model used can be found [here](#).





Olası Hidden State Sekansının Bulunması

Gözlemlenen sekansı veren Hidden State sekanslarının bulunması gereklidir. Farklı path'ler çıkarılabilir ancak amaç en iyi path bulmaktır.



Maksimum olasılığı veren path aranır. Bunu için partial probability hesaplanır.

$$\delta_1(i) = \pi(i)b_{ik_1}$$

Slide 22

Viterbi Algoritması

$$\delta_1(i) = \pi(i)b_{ik_1}$$

$$\delta_t(i) = \max_j(\delta_{t-1}(j)a_{ji}b_{ik_t})$$

$$\phi_t(i) = argmax_j(\delta_{t-1}(j)a_{ji})$$

Slide 23

SCHOOL OF LEEDS

[Edit](#) [View](#) [Favorites](#) [Tools](#) [Help](#)

Search Favorites Media

ss http://www.comp.leeds.ac.uk/roger/HiddenMarkovModels/html_dev/viterbi_algorithm/s3_pg3.html Go

Viterbi Algorithm

Finding probability Definition Example Summary

Section 3 - Page 3
1 2 3 4 5

Valid States : Dry Dryish Damp Soggy

Dry,Damp Set

Step	Sunny
Run	Cloudy
	Rainy
D	D
y	a
	m
	p

New states have been set

A full description of the model used can be found [here](#).

Page 4

SCHOOL OF LEEDS

[Edit](#) [View](#) [Favorites](#) [Tools](#) [Help](#)

Search Favorites Media

ss http://www.comp.leeds.ac.uk/roger/HiddenMarkovModels/html_dev/viterbi_algorithm/s3_pg3.html Go

Viterbi Algorithm

Finding probability Definition Example Summary

Section 3 - Page 3
1 2 3 4 5

Valid States : Dry Dryish Damp Soggy

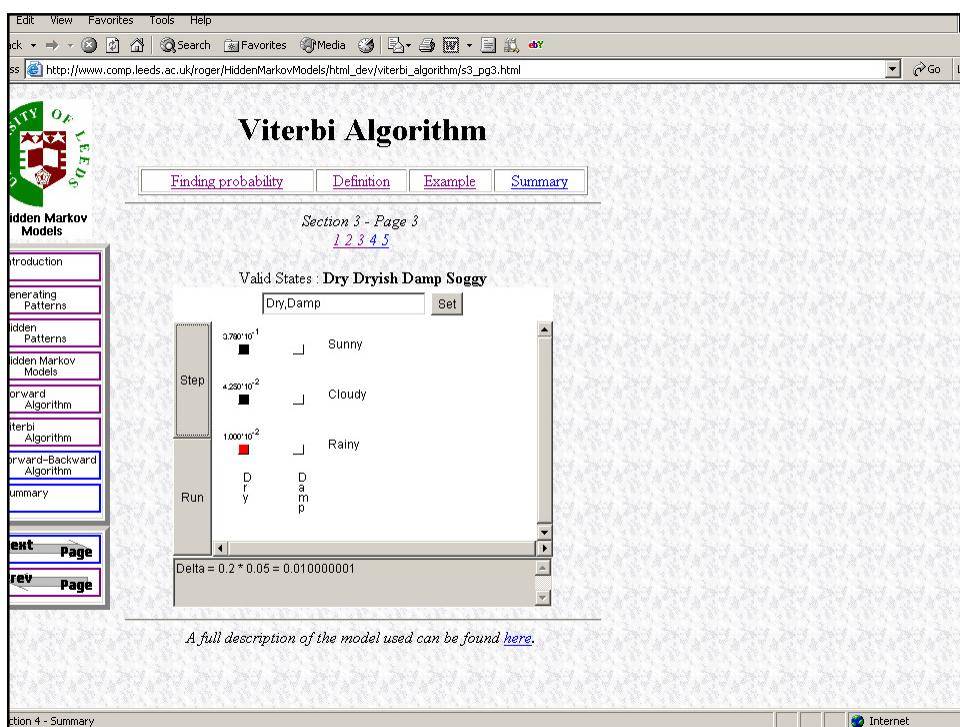
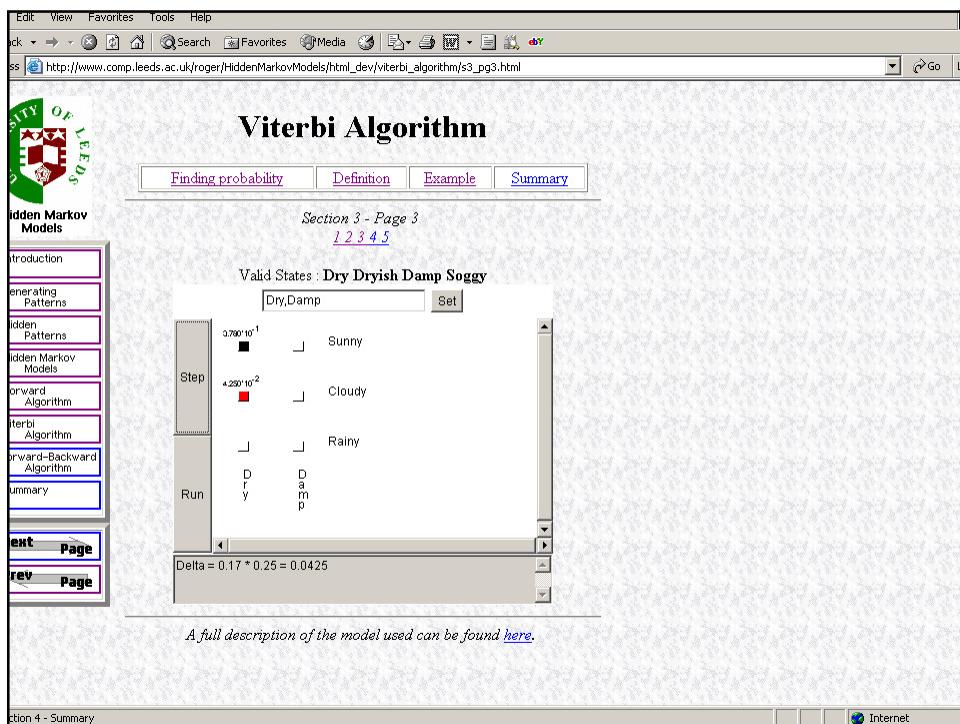
Dry,Damp Set

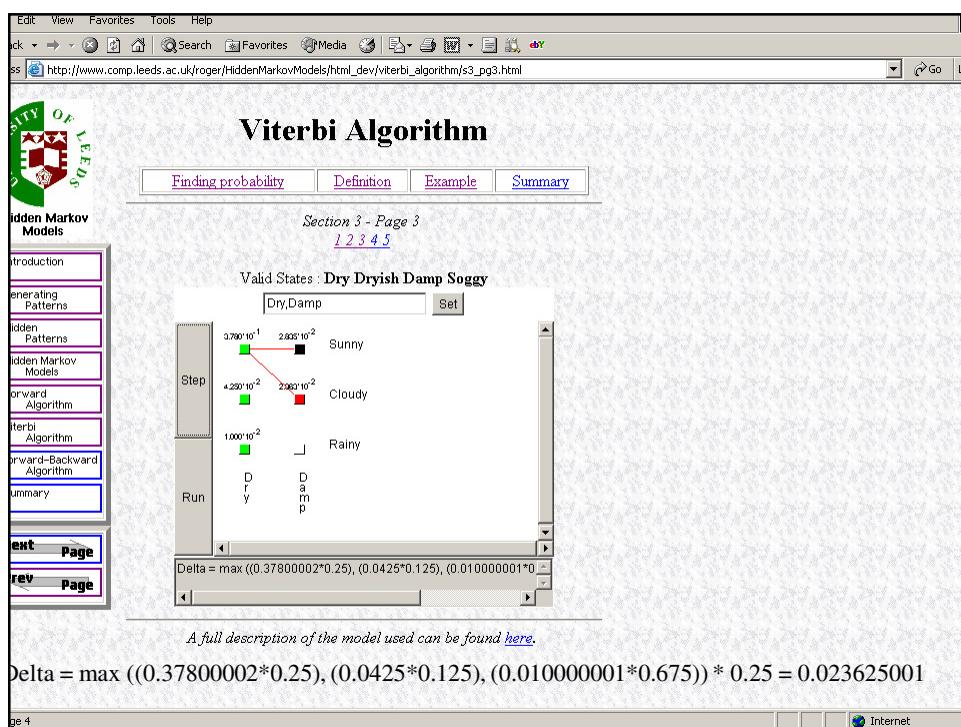
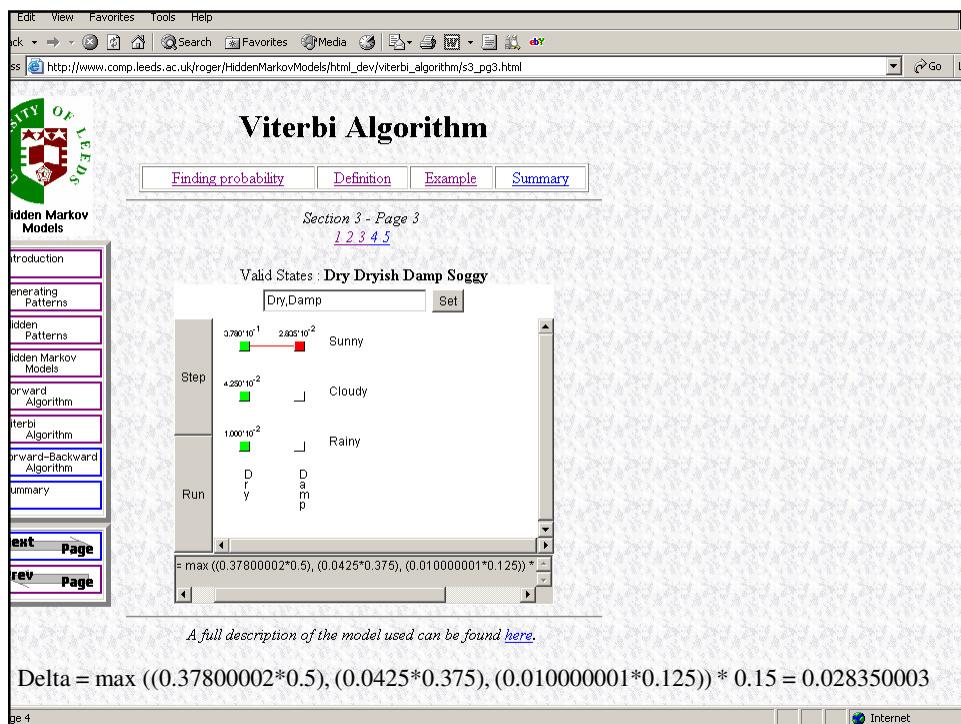
Step	Sunny
Run	Cloudy
	Rainy
D	D
y	a
	m
	p

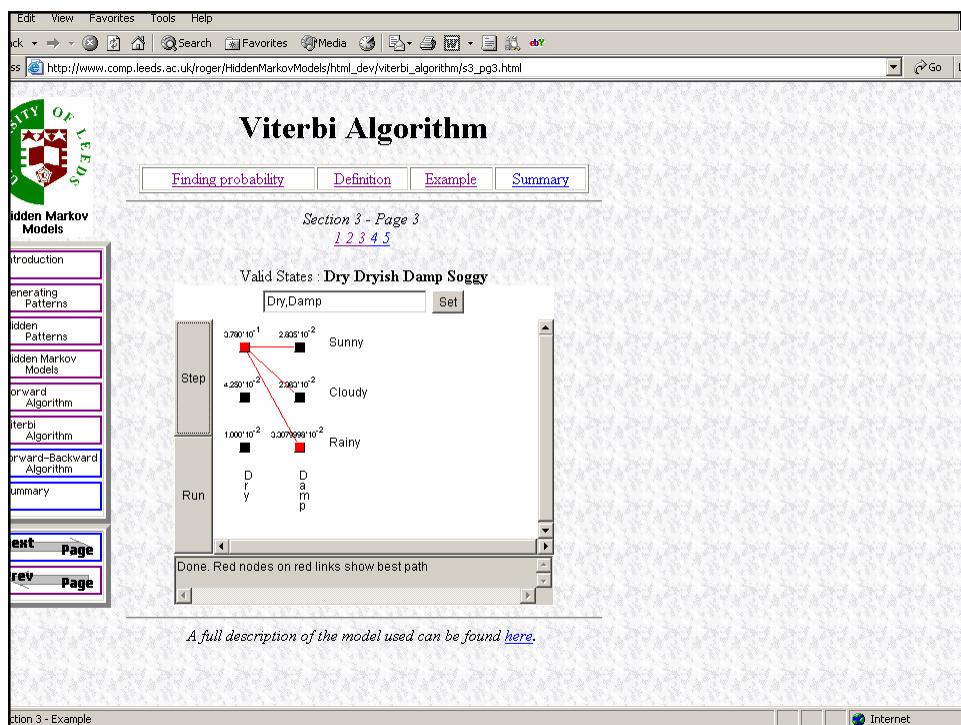
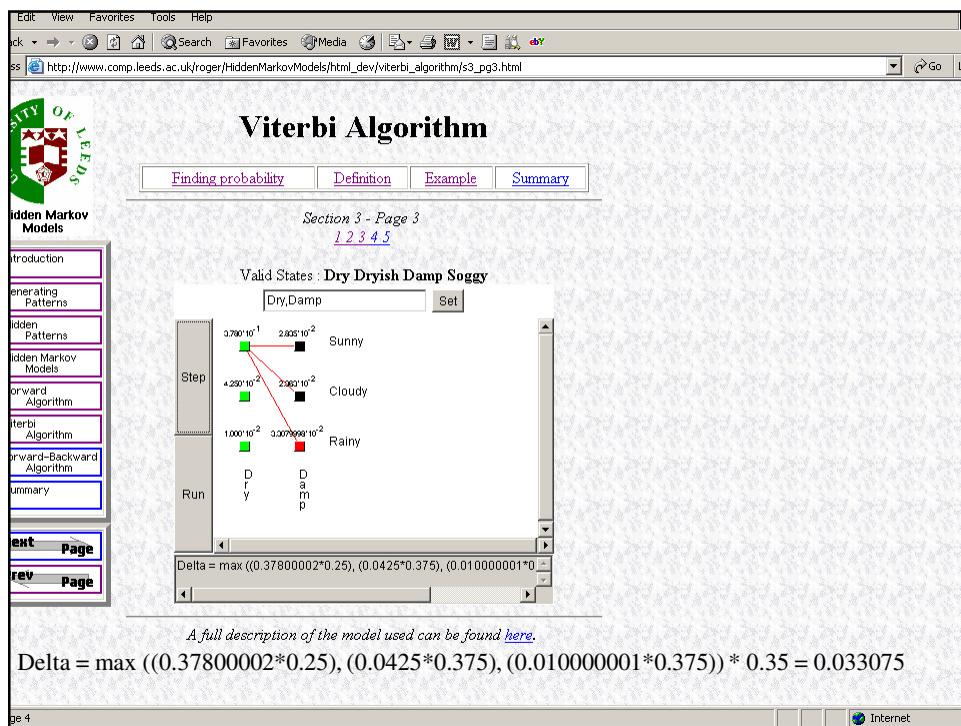
Delta = 0.63 * 0.6 = 0.37800002

A full description of the model used can be found [here](#).

Page 4 - Summary







Kaynaklar

http://www.comp.leeds.ac.uk/roger/HiddenMarkovModels/html_dev/main.html

Slide 32